

# Reconocimiento de patrones

Clase 10: K means



# Para el día de hoy...

- K means







# Antes de empezar

---

- Entregar en un documento pdf de una página los siguientes elementos para definir el proyecto final del curso:
  - Título
  - Miembros del equipo (máx. 3)
  - Descripción del problema ¿Qué no está sucediendo?
- ¿Quién está interesado?
- ¿Por qué es de interés para ustedes?
- ¿Qué previene que se haga?
- ¿Qué pasa si no se hace?
- ¿Qué se planea hacer? (en términos de lo existente y las operaciones básicas para transformar)
- ¿Cómo luce el éxito?

# K means



¿Cuál es la idea?



¿Cuáles son las suposiciones?



¿Cuáles son las entradas?



¿Cuál es la salida?



¿Dadas las mismas entradas, la salida es siempre la misma?



¿Cuál es el algoritmo?

# Un poco de explicación

- Dado un conjunto de datos  $X = \{x_1, x_2, \dots, x_m\}$ , suponemos la existencia de  $k$  grupos
- Los centros son aproximados por  $y_1^{(0)}, \dots, y_k^{(0)}$
- Los grupos se encuentran de forma iterativa
- En cada paso todos los patrones se clasifican y cada centro se ajusta usando la media aritmética de las muestras del grupo hasta que entre dos iteraciones los grupos no cambien

# El algoritmo

**Output:**  $\{y_j\}$ ,  $1 \leq j \leq c$  – the final cluster centers.  
 $\{m_j\}$ ,  $1 \leq j \leq c$  – the cluster sizes.  
 $\{l_{ij}\}$ ,  $1 \leq i \leq m_j$  – the indices of the original samples which belong to the  $j$  cluster,  $1 \leq j \leq c$ .  
 $it$  – the number of iterations needed for convergence.

- Step 1.** Initialization: set  $y_{j0} = x_j$ ,  $1 \leq j \leq c$  and  $it = 0$ .
- Step 2.** Classify  $\{x_i\}_{i=1}^m$  about the cluster centers  $\{y_{j0}\}_{j=1}^c$  using the minimum distance classifier. For  $1 \leq j \leq c$  denote by  $\{x_{l_{ij}}\}_{i=1}^{m_j}$  the samples which cluster around  $y_{j0}$ .
- Step 3.** For  $1 \leq j \leq c$  obtain  $y_j$  which minimizes the performance index

$$I_j(z) = \sum_{i=1}^{m_j} \|z - x_{l_{ij}}\|^2, \quad z \in R^n \quad (3.3.12)$$

Basic calculus implies

$$y_j = \left( \sum_{i=1}^{m_j} x_{l_{ij}} \right) / m_j \quad (3.3.13)$$

i.e.  $y_j$  is the arithmetic mean of  $\{x_{l_{ij}}\}_{i=1}^{m_j}$ . Set  $it \leftarrow it + 1$ .

- Step 4.** If

$$y_j = y_{j0}, \quad 1 \leq j \leq c \quad (3.3.14)$$

output  $y_j, m_j, \{x_{l_{ij}}\}_{i=1}^{m_j}$ ,  $1 \leq j \leq c$ ;  $it$  and stop. Otherwise, if  $it > N$  output 'number of iterations exceeded'; else set  $y_{j0} = y_j$  and go to Step 2.

# Las preguntas



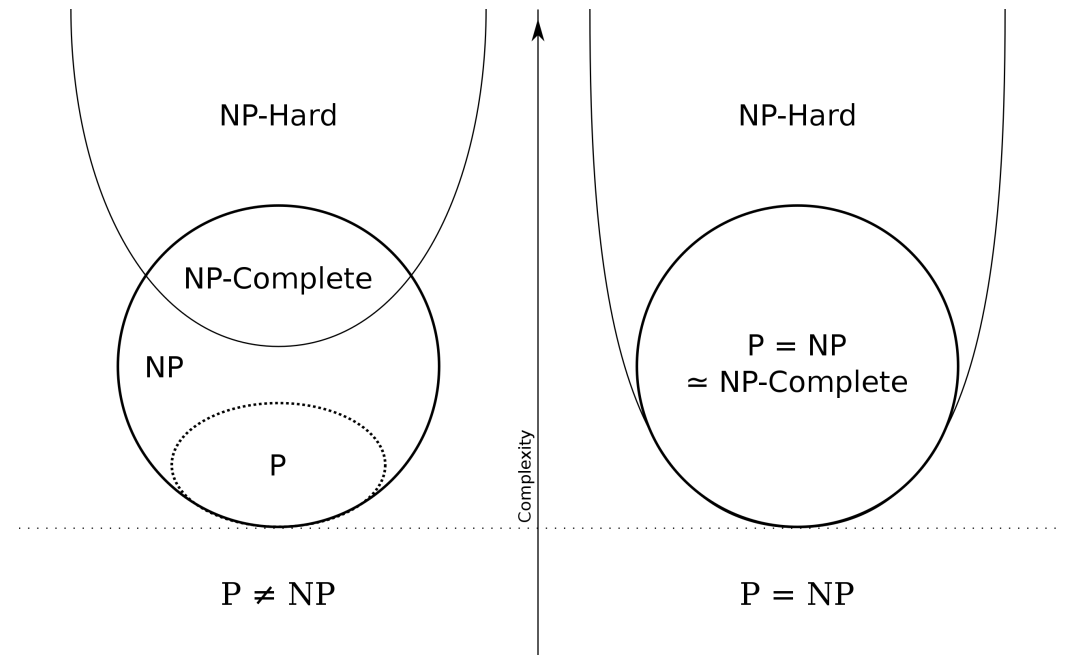


# Un detour a complejidad computacional

- La elección óptima para  $k$  y  $y_{j0}$  así como las condiciones de convergencia del algoritmo no son conocidas
- La función objetivo de k-means es

$$\arg \min_C \sum_{i=1}^k \sum_{x_j \in C_i} \|x_j - \mu_i\|^2$$

- Este problema es NP-Hard



# La clases de problemas

**La clase P:** contiene aquellos problemas que pueden resolverse en tiempo polinomial con una MT determinista.

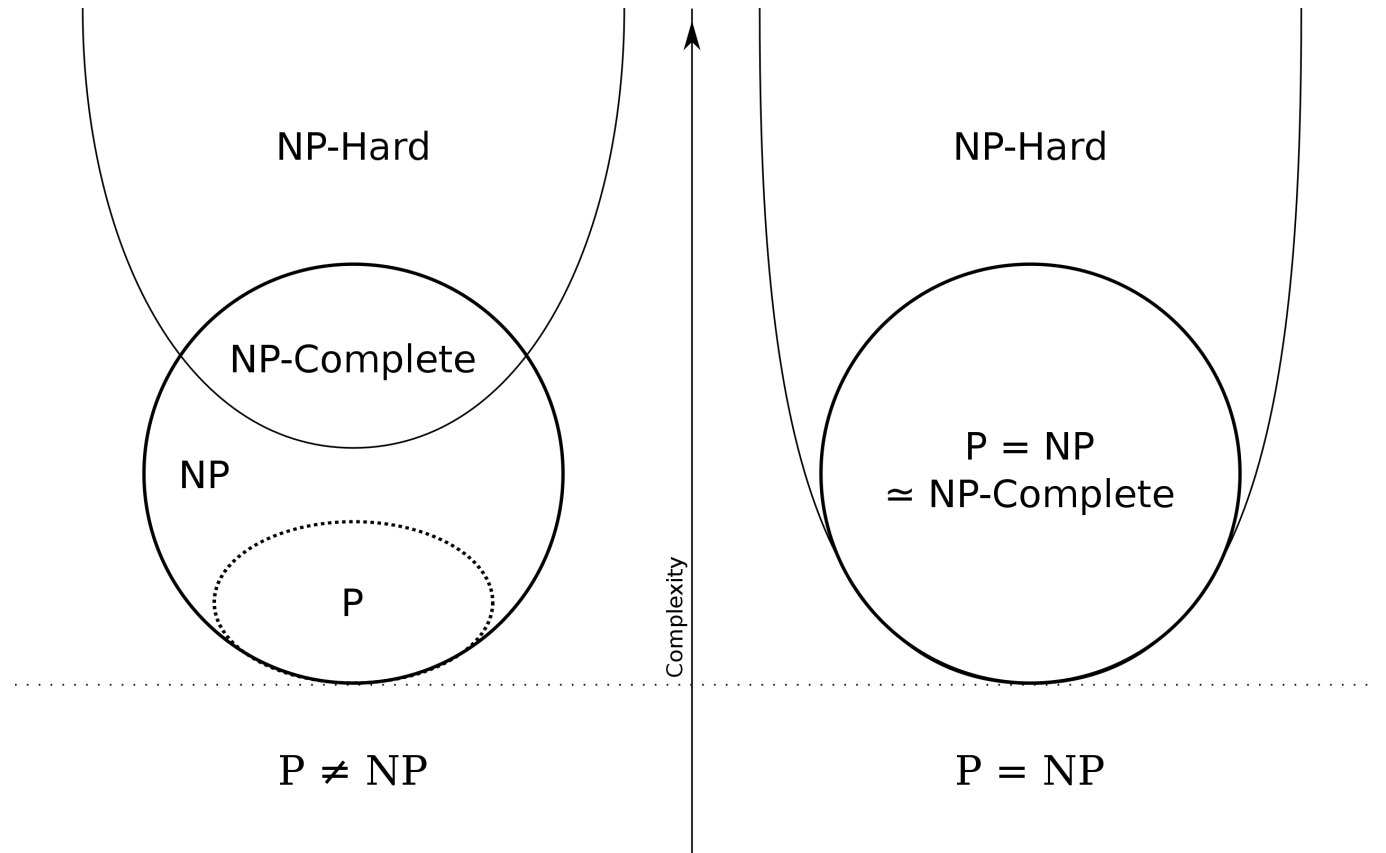
- Buscar un número en un arreglo ordenado o desordenado
- Ordenar un arreglo
- Ruta más corta en un grafo
- Suma, multiplicación de polinomios

**La clase NP:** contiene aquellos problemas que pueden resolverse en tiempo polinomial con una MT no determinista

- Satisfacción de fórmulas boolean
- Problema de la mochila
- Problema del viajero

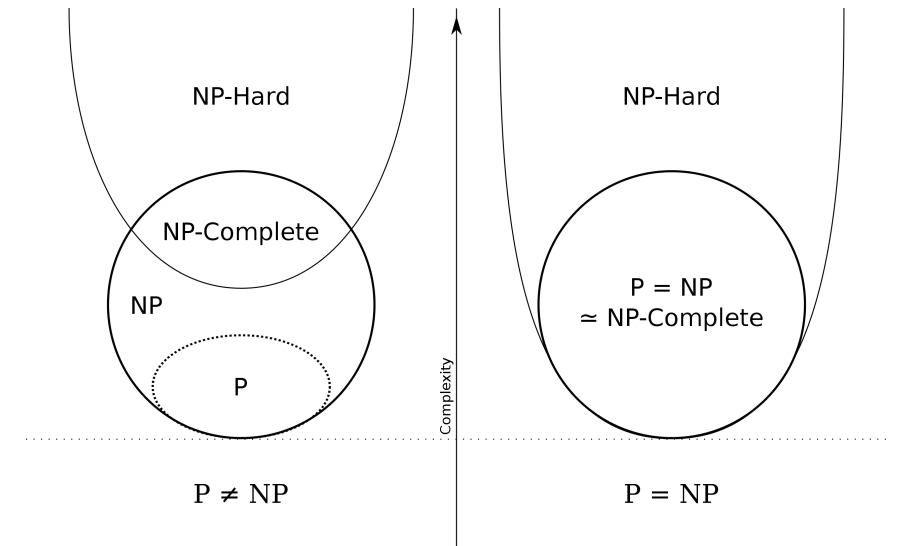
# Problemas NP completos

- Se dice que un problema es NP completo si las siguientes afirmaciones sobre un lenguaje  $L$  son verdaderas:
  - Pertenece a NP
  - Para todo lenguaje  $L'$  perteneciente a NP existe una reducción en tiempo polinomial de  $L'$  a  $L$



# Problemas NP-difíciles

- Algunos problemas  $L$  son tan difíciles que aunque podamos demostrar la condición 2 de la definición, no se puede demostrar la condición 1.
- En esos casos decimos que  $L$  es NP-difícil.
- Una demostración de que  $L$  es NP-difícil basta para demostrar que  $L$  es muy probable que requiera un tiempo exponencial o aún peor.





# Para la otra vez...

- ISO Data



iimas

A close-up photograph of a typewriter's carriage and typebars, with the words "The End." printed on a sheet of paper emerging from it.

The End.